

22/07/2026

Prédiction chimométrique de la teneur en humidité des grains de café par spectroscopie FT-NIR : Évaluation comparative des modèles PLS et Random Forest

Jean-pierre DEBS

1. Introduction et architecture de l'ensemble de données

La spectroscopie proche infrarouge (NIRS en anglais), opérant dans la plage de 12000 à 4000 cm^{-1} , offre une méthode optique rapide et non destructive pour le suivi de l'humidité lors du séchage industriel de produits agricoles comme le café en parche. Le jeu de données évalué dans cette étude comprend 73 spectres obtenus à partir de 20 échantillons distincts. Ces données contiennent 2 001 variables spectrales mesurées avec un pas de 4 cm^{-1} , ainsi que 6 variables descriptives.

D'un point de vue méthodologique, une distinction rigoureuse s'impose entre les différents niveaux d'acquisition. Une observation spectrale correspond à l'enregistrement d'un spectre optique unique par l'instrument à un instant donné. Une répétition désigne une mesure consécutive effectuée sur la même prise d'essai sans repositionnement, servant à évaluer la stabilité instrumentale. Enfin, un échantillon indépendant représente un lot physique distinct de grains de café, possédant son propre taux d'humidité de référence.

Il est à noter que le nombre d'observations par échantillon n'est pas constant au sein de ce corpus ; on compte en moyenne 3,65 mesures par échantillon indépendant. La vérification de cette structure de données a confirmé l'absence totale de valeurs manquantes et de doublons stricts.

L'humidité de référence (sur base humide) varie de 8,50 % à 52,49 %, avec une moyenne de 32,29 % et une médiane de 35,74 %. Toutefois, comme l'illustre la distribution des échantillons (Figure 1), le gradient d'humidité n'est pas continu. Les données se concentrent en trois groupes distincts représentant les phases clés du séchage : un groupe « wet » entre 48 et 52 % d'humidité, un groupe « semi-dried » entre 30 et 42 % d'humidité, et un groupe « dry » entre 8 et 19 % d'humidité.




Figure 1: Distribution de la teneur en humidité (sur base humide) au sein du jeu de données. L'histogramme et la courbe de densité (KDE) mettent en évidence la fragmentation des échantillons en trois groupes distincts (« dry », « semi-dried », « wet »). Les lignes verticales pointillées indiquent la moyenne (rouge, 32,29 %) et la médiane (verte, 35,74 %) globales.

2. Analyse exploratoire des données et transformations spectrales

Les fichiers spectraux bruts ont été importés et convertis de la réflectance vers la pseudo-absorbance ($A = \log_{10}(\frac{100}{R})$). Cette transformation permet de linéariser la réponse instrumentale en fonction des concentrations, conformément à la loi de Beer-Lambert.

La Figure 2 illustre ces profils spectraux pour chaque échantillon indépendant. Si elle confirme une bonne répétabilité globale des mesures successives pour un même échantillon, elle souligne également d'importants décalages de la ligne de base d'un lot à l'autre. Cependant, cette répétabilité intra-

échantillon est remise en question pour certains lots (M02, M03, M10 et M18), qui présentent des variations d'intensité liées à la ligne de base pour une même prise d'essai et un même taux d'humidité, et non à des différences chimiques. Cela suggère la nécessité d'une étude des valeurs atypiques (outliers) pour déterminer si ces écarts résultent d'artefacts spectraux ou de problèmes de diffusion de la lumière (scattering). Il est important de noter que ces quatre échantillons variables représentent quatre des cinq lots présentant une humidité supérieure à 50 %. L'échantillon M01 est le seul lot très humide (« wet ») affichant un comportement constant, malgré une légère différence d'intensité autour du pic à 5200 cm^{-1} (bien moins marquée que pour les quatre autres). Cela laisse supposer que plus la teneur en eau de l'échantillon est élevée, plus la probabilité d'observer des variations spectrales dues à la diffusion de la lumière augmente. Il convient de rappeler que ces observations concernent des spectres bruts, avant l'application de prétraitements mathématiques.




Figure 2: Spectres d'absorbance bruts regroupés par échantillon indépendant (M01 à M20).

Pour évaluer l'intégrité des échantillons et détecter d'éventuelles anomalies d'acquisition, une analyse en composantes principales (PCA) exploratoire a été menée conjointement à une étude de la distance de Mahalanobis. La PCA est une technique de réduction de dimensionnalité qui permet de visualiser les principales sources de variance des données. La distance de Mahalanobis, quant à elle, mesure l'éloignement multivarié d'un spectre par rapport au centre de gravité du jeu de données en tenant compte de la covariance inter-variables. Cette distance a été calculée en utilisant une limite de confiance à 99 % basée sur une distribution χ^2 . Bien que l'approche de Mahalanobis n'ait révélé aucun point aberrant, les diagnostics PCA, basés sur le T^2 de Hotelling et les Q-residuals avec un seuil de confiance de 99 %, offrent une perspective différente. Comme l'indique la Figure 3, la projection de ces limites PCA permet d'identifier un point atypique isolé dépassant le seuil critique du T^2 de Hotelling, tout en confirmant la stabilité et la qualité du reste du jeu de données. Ce point aberrant correspond au scan 5 de l'échantillon M10, ce qui corrobore l'observation précédente concernant la forte variabilité des échantillons très humides. Il est également légitime de supposer que les quelques points qui se rapprochent

dangereusement des limites de confiance (lignes en pointillés) correspondent tous aux échantillons très humides affichant cette forte variabilité.




Figure 3: Diagnostic des valeurs atypiques issu de la PCA exploratoire. Le graphique croise le T^2 de Hotelling (axe des abscisses) et les Q -residuals (axe des ordonnées). Les limites de confiance à 99 % sont représentées par les lignes en pointillés, mettant en évidence un spectre potentiellement aberrant dans le coin supérieur droit.




Figure 4: Spectres FT-NIR moyens et limites d'écart-type (± 1 SD) pour les trois clusters d'humidité (Dry, Semi-dried, Wet) identifiés par K-Means. L'enveloppe bleutée illustre la variance importante et l'absorbance élevée caractéristique des échantillons fraîchement récoltés (Wet).

De plus, la segmentation du jeu de données par l'algorithme K-Means en trois phases d'hydratation distinctes (Dry, Semi-dried et Wet) met en évidence des profils de variance spectrale spécifiques. La Figure 4 présente les spectres moyens et leurs limites d'écart-type pour chaque phase. Cette visualisation montre que la ligne de base et l'intensité des bandes fluctuent fortement selon le stade de séchage. Le groupe « Wet » se démarque par une absorbance globale beaucoup plus forte et, comme mentionné précédemment, par une dispersion intragroupe (variance) nettement supérieure, tandis que les groupes « Semi-dried » et « Dry » affichent des profils spectraux très proches et plus stables. Outre l'élévation évidente de la ligne de base, les différences spectrales les plus marquées entre le groupe très humide et les deux autres groupes se situent entre 4500 et 5500 cm^{-1} . Dans cette région, qui englobe la bande de combinaison des déformations et elongations O-H près de 5150 cm^{-1} , les bandes d'absorption des échantillons « Wet » présentent un fort chevauchement, tandis qu'elles apparaissent beaucoup mieux définies lorsque l'humidité descend en dessous de 40 %. De plus, les bandes majeures d'absorption de l'eau situées autour de 6900 cm^{-1} , correspondant à la première harmonique de l'elongation O-H, montrent également une absorbance plus élevée pour le groupe très humide par rapport aux échantillons séchés et semi-séchés.

3. Méthodologie de prétraitement spectral

Les spectres proche infrarouge bruts issus de milieux agricoles granulaires sont inévitablement perturbés par la diffusion physique de la lumière, l'hétérogénéité de la taille des particules, les variations de densité de tassement et les déviations de la ligne de base. Pour isoler l'information chimique de ces artefacts physiques, la transformation SNV (Standard Normal Variate) et le filtre de Savitzky-Golay en dérivée première (SG1) ont été évalués.

En premier lieu, le filtre SG1 (polynôme d'ordre 2, fenêtre de 25 points) a été envisagé pour éliminer les pentes linéaires résiduelles, séparer les bandes d'absorption superposées et accentuer le contraste autour des régions d'absorption de l'eau. Cependant, l'utilisation du SG1 seul s'est avérée insuffisante. Comme établi précédemment, les échantillons très humides présentent une forte variabilité inter-échantillons causée par la diffusion physique de la lumière. Si la dérivée corrige très bien les décalages additifs de la ligne de base, elle ne compense pas les effets multiplicatifs (liés aux différences de trajet optique) typiques de cette forte diffusion. De plus, appliquer une transformation dérivée sans normaliser préalablement la ligne de base ne fait qu'amplifier le bruit instrumental à haute fréquence.

C'est pourquoi la transformation SNV a ensuite été appliquée seule sur les données brutes. Celle-ci centre et met à l'échelle chaque spectre pour obtenir une variance unitaire, éliminant ainsi avec succès les décalages multiplicatifs induits par la diffusion physique (Figure 5). Bien que le SNV corrige efficacement la ligne de base, la nature superposée des pics en proche infrarouge pose toujours problème. Comme souligné précédemment, la forte présence d'eau masque les signaux sous-jacents, rendant la distinction des pics individuels beaucoup plus difficile que sur les spectres des échantillons secs.




Figure 5: Comparaison des spectres bruts (à gauche) et des spectres prétraités par SNV (à droite), colorés selon leur teneur en humidité. La transformation SNV corrige efficacement les importants décalages multiplicatifs de la ligne de base.

Le choix s'est donc porté sur l'application séquentielle du SNV suivi du SG1. Cette combinaison permet de bénéficier à la fois de la correction de la diffusion lumineuse et de la capacité de la dérivée première à faire ressortir les pics d'absorption (Figure 6).

Le risque de sur-filtrage a été soigneusement évité pour ne pas déformer artificiellement les pics d'absorption étroits. Pour ce faire, le SG1 a été testé avec différentes tailles de fenêtre (15, 25 et 35) sur les données préalablement traitées par SNV. Une fenêtre de 15 points laisse persister un bruit à haute fréquence (particulièrement visible dans la région sans absorption entre 12000 et 10000 cm^{-1}), tandis qu'une fenêtre de 35 points lisse excessivement le signal, écrasant l'intensité et la résolution des pics les plus fins (entre 4000 et 5000 cm^{-1}). Une fenêtre de 25 points s'est donc révélée être le meilleur compromis.

Enfin, une seconde étude des valeurs atypiques a été réalisée sur les spectres prétraités par SNV + SG1, selon la même approche que précédemment. Cette analyse montre que les données sont désormais beaucoup plus compactes et que l'anomalie détectée sur les spectres bruts est corrigée. Cela confirme la validité et l'importance de la méthode de prétraitement retenue.

Cependant, cette nouvelle évaluation a mis en évidence l'apparition d'un autre spectre atypique. Ce dernier n'a été détecté ni par la distance de Mahalanobis ni par le T^2 de Hotelling, mais uniquement par les Q-residuals de la PCA. Il s'agit du scan 3 de l'échantillon M02, qui correspond à nouveau à l'un de ces lots très humides affichant une forte variabilité.




Figure 6: Comparaison entre les spectres prétraités par SNV seul (en haut) et ceux traités par l'enchaînement SNV + SG1 en dérivée première (en bas). L'application séquentielle du filtre SG1 permet de résoudre les bandes d'absorption superposées sans amplifier excessivement le bruit.

Afin de vérifier la pertinence de cette alerte, ce spectre a été comparé visuellement avec la moyenne des autres scans du lot M02 et avec la moyenne du cluster « Wet » (sans l'outlier). Aucune différence flagrante ni variance excessive n'a été observée. Il en a été conclu que ce spectre a été signalé en raison de son écart par rapport à la moyenne globale du jeu de données, et non par rapport à son environnement local. Puisqu'il ne présente pas d'anomalie structurelle majeure au sein de son propre groupe, la décision a été prise de ne pas le retirer de la procédure de modélisation.

4. Stratégie de modélisation chimiométrique et de validation

La construction de modèles de régression robustes pour des données spectrales en haute dimension, où le nombre de variables dépasse largement le nombre d'échantillons indépendants, nécessite une réduction de dimensionnalité. La régression classique des moindres carrés (OLS) échoue dans ce contexte en raison de la forte multicollinéarité et de la singularité des matrices. Par conséquent, une régression des moindres carrés partiels (PLS) a été mise en œuvre pour projeter la matrice spectrale sur des variables latentes orthogonales qui maximisent la covariance avec l'humidité cible.

Pour éviter toute fuite de données (data leakage), la validation a été structurée en utilisant une stratégie de validation croisée « Leave-One-Group-Out » (LOGO) basée strictement sur les identifiants des échantillons d'origine. Cette méthode a été choisie car une séparation aléatoire classique des spectres individuels est méthodologiquement invalide ici : des mesures répétées successives provenant du même lot physique de café se retrouveraient à la fois dans les ensembles d'entraînement et de validation. Le modèle reconnaîtrait alors l'empreinte physique de l'échantillon plutôt que d'apprendre à prédire la chimie, ce qui gonflerait artificiellement ses performances.

La complexité du modèle, c'est-à-dire le nombre optimal de composantes PLS, a été déterminée exclusivement sur les ensembles d'entraînement en minimisant l'erreur quadratique moyenne de validation croisée (RMSECV). Plutôt que de sélectionner aveuglément le nombre de composantes donnant l'erreur absolue la plus basse (ce qui conduit souvent à capturer le bruit instrumental et donc au surajustement), la méthode du coude (« elbow method ») a été appliquée avec un seuil statistique. Le point d'inflexion de la courbe d'erreur (le coude) a été sélectionné car il offre le meilleur compromis : il capture la majorité de la variance chimique utile (>10%) tout en conservant un modèle plus simple, plus parcimonieux et plus robuste pour la généralisation (Figure 7).




Figure 7: Courbe de sélection de la complexité du modèle PLS via la validation croisée Leave-One-Group-Out (LOGO). Le graphique illustre l'évolution de la RMSECV en fonction du nombre de composantes, mettant en évidence le point du « coude » sélectionné pour éviter le surajustement par rapport au minimum d'erreur absolue

Les résultats détaillés de ces prédictions seront évalués dans la section suivante. Toutefois, pour disposer d'un point de comparaison face au modèle PLS, un second modèle de régression basé sur l'algorithme des Forêts Aléatoires (Random Forest - RF) a été entraîné en utilisant les mêmes variables d'entrée. Le RF a été sélectionné car il s'agit d'une méthode d'apprentissage automatique non linéaire, basée sur un ensemble d'arbres de décision. Contrairement à la PLS qui modélise des relations linéaires globales via des variables latentes, le RF divise l'espace des données de manière non linéaire et gère nativement la colinéarité sans nécessiter de réduction de dimensionnalité préalable. Ce modèle a été paramétré avec une forêt de 500 arbres et ses performances ont été évaluées via la même stratégie LOGO pour assurer une comparaison rigoureuse.

5. Évaluation comparative et performances des modèles

Une évaluation critique des performances prédictives des modèles PLS et Random Forest (RF) a été menée en analysant leurs métriques d'erreur globales et la distribution de leurs résidus sur l'ensemble de test. L'examen des indicateurs statistiques révèle une supériorité globale évidente du modèle Random Forest (Table 1).

Ce modèle affiche une erreur quadratique moyenne (RMSE) de 1,40 et une erreur absolue moyenne (MAE) de 1,23, des valeurs nettement inférieures à celles obtenues avec le modèle PLS (RMSE de 2,20 et MAE de 1,75). Cette meilleure précision s'accompagne d'un coefficient de détermination (R^2) de 0,993 pour le RF, contre 0,982 pour la PLS, indiquant que l'approche par forêt aléatoire parvient à expliquer une fraction plus importante de la variance des données. Les deux modèles présentent un biais moyen positif (1,07 pour la PLS et 0,99 pour le RF), ce qui traduit une légère tendance systématique à surestimer le taux d'humidité.

Afin d'évaluer la stabilité des prédictions, les écarts-types ont été calculés d'une part sur la distribution des erreurs absolues individuelles de l'ensemble de test (pour la MAE), et d'autre part sur la distribution des résidus bruts (pour le biais). L'intégration de ces mesures de dispersion met explicitement en exergue les limites de l'approche linéaire face à des données physiquement fragmentées. Pour la PLS, l'écart-type du biais ($\pm 1,92$) est presque le double de sa moyenne globale. Couplée à une variance élevée de la MAE ($\pm 1,33$), cette dispersion démontre que l'erreur prédictive de la PLS n'est absolument pas uniforme. Le modèle fluctue de manière erratique, une conséquence directe de son incapacité à interpoler correctement dans les zones vides séparant les clusters d'humidité discontinus.

Table 1: Comparaison des indicateurs statistiques de performance pour les modèles de régression PLS et Random Forest (RF) sur l'ensemble de test. Les métriques évaluées incluent l'erreur quadratique moyenne (RMSE), l'erreur absolue moyenne (MAE), le coefficient de détermination (R^2) et le biais moyen pour la prédiction du taux d'humidité.

	RMSE	MAE	R^2	Mean Bias
PLS	2,20	$1,75 \pm 1,32$	0,982	$1,07 \pm 1,92$
Random Forest	1,40	$1,23 \pm 0,67$	0,992	$0,99 \pm 0,99$

L'analyse visuelle des diagnostics (Figure 8) confirme cette dynamique et met clairement en évidence la supériorité du modèle RF sur la régression linéaire PLS. Le nuage de points du RF est nettement plus resserré autour de la droite d'identité. Bien que le R^2 de la PLS (0,982) semble performant sur le papier, la forte variance de ses résidus prouve que cette métrique est artificiellement étirée par la distance extrême entre les clusters d'échantillons, masquant une précision locale défailante. La meilleure adéquation du RF s'illustre par la réduction drastique de l'amplitude des erreurs : alors que les résidus de la PLS s'étalent sur une large plage allant de -2,5 à +3,5, le modèle RF contient la quasi-totalité de ses erreurs entre -2,0 et +2,0. L'erreur absolue maximale chute ainsi de 3,5 pour la PLS à moins de 2,2 pour le RF, démontrant la capacité de l'algorithme non linéaire à contraindre efficacement les écarts extrêmes.




Figure 8: Diagnostics du modèle PLS (en haut) et RF (en bas) sur l'ensemble de test. La figure présente les valeurs d'humidité prédites en fonction des valeurs mesurées, la distribution des résidus par rapport aux prédictions, ainsi que la répartition de l'erreur absolue.

Malgré cette meilleure précision globale, il apparaît que les deux modèles restent sensibles aux variations optiques (diffusion lumineuse) propres à chaque stade de séchage. La PLS souffre d'une structure d'erreur très hétérogène, peinant particulièrement sur les clusters extrêmes (les échantillons très humides et ceux séchés autour de 10–15 %) où la variance explose. Si le modèle RF parvient à lisser

l'amplitude de ces erreurs—ce qui est mathématiquement validé par la chute de l'écart-type sur sa MAE ($\pm 0,67$) et son biais ($\pm 0,99$)—il conserve néanmoins une structure de groupe résiduelle. Il a tendance à surestimer l'humidité des échantillons secs et très humides (résidus positifs), et à la sous-estimer pour le groupe intermédiaire semi-séché (résidus négatifs). L'algorithme RF optimise donc fortement la prédiction, mais n'élimine pas totalement le biais induit par la segmentation physique initiale des grains.

6. Interprétation et recommandations

Le modèle Random Forest (RF) s'avère nettement plus robuste que la régression PLS pour prédire l'humidité des grains de café. Ses métriques d'erreur (RMSE de 1,40 et MAE de $1,23 \pm 0,67$) et son coefficient de détermination (R^2 de 0,99) démontrent sa capacité supérieure à gérer les variations non linéaires du signal spectral. Cette performance optimale repose sur le prétraitement séquentiel combinant la correction de diffusion SNV et la dérivée première de Savitzky-Golay (fenêtre de 25). Cette combinaison s'est révélée la plus efficace pour corriger les effets de diffusion lumineuse physique et isoler l'information chimique liée aux liaisons de l'eau.

Toutefois, les performances ne sont pas parfaitement homogènes sur l'ensemble de la plage d'humidité. L'analyse des résidus a montré que le modèle RF, bien qu'il limite fortement les erreurs extrêmes par rapport à la PLS, conserve une empreinte liée à la segmentation des données. Les écarts-types associés à l'erreur absolue et au biais prouvent que la précision prédictive fluctue fortement d'un groupe d'échantillons à l'autre. La base de données n'étant pas continue (fragmentée en trois clusters : 8-19 %, 30-42 % et 48-52 %), le modèle a tendance à systématiquement surestimer l'humidité aux extrêmes (café très sec ou très humide) et à la sous-estimer dans la zone intermédiaire.

Le risque de surapprentissage algorithmique lors de la modélisation a été strictement contrôlé en appliquant la validation croisée Leave-One-Group-Out (LOGO). En basant la séparation sur les identifiants physiques des échantillons, le modèle a été empêché de mémoriser les répliques de scan, évitant ainsi toute fuite de données. Néanmoins, un risque de surapprentissage lié à la structure des données persiste : le modèle excelle sur les trois clusters connus, mais pourrait se montrer imprécis s'il devait interpoler des valeurs d'humidité situées dans les plages manquantes (par exemple, entre 20 % et 30 %).

En l'état, le modèle constitue une excellente preuve de concept mais n'est pas encore suffisamment fiable pour un déploiement industriel à l'aveugle. Pour atteindre ce stade, il est fortement recommandé de procéder à l'acquisition de données supplémentaires permettant un échantillonnage continu. Il s'avère nécessaire de mesurer des échantillons couvrants progressivement toutes les étapes intermédiaires du séchage pour combler les vides actuels, et d'intégrer une plus grande variabilité biologique (différentes origines, saisons ou variétés).

Une fois ce modèle enrichi, une validation externe formelle devra être organisée. Celle-ci nécessitera un lot de café de test totalement indépendant, issu d'une campagne de production distincte, mesuré par d'autres opérateurs et à une date différente. Cette étape validera la véritable capacité du modèle à résister aux dérives instrumentales et aux variations environnementales.

À terme, ce modèle chimiométrique a vocation à piloter directement le processus industriel. L'intégration se fera par le déploiement d'un capteur FT-NIR en ligne (in-line) ou en bord de ligne (at-line) au niveau des séchoirs. Le modèle RF traduira les spectres acquis en temps réel pour monitorer la cinétique de séchage. Le système pourra ainsi générer une alerte automatisée ou couper la chauffe dès que la cible d'humidité de conservation (autour de 10 à 12 %) sera atteinte, évitant le sur-séchage et optimisant les coûts énergétiques.