

Résumé opérationnel

Contexte et objectif

Le séchage industriel du café en parche est une étape critique nécessitant un suivi précis de l'humidité pour garantir la conservation des grains et optimiser les coûts énergétiques. L'objectif de cette étude est de développer un modèle chimiométrique prédictif non destructif basé sur la spectroscopie proche infrarouge par transformée de Fourier (FT-NIR) pour estimer la teneur en humidité (sur base humide, de 8,50 % à 52,49 %).

Traitement des données et approche méthodologique

Le corpus s'appuie sur 73 spectres (2 001 variables) répartis sur 20 échantillons indépendants. L'analyse exploratoire par ACP et K-Means a révélé une forte fragmentation des données en trois clusters d'hydratation distincts (*Dry* : 8–19 %, *Semi-dried* : 30–42 %, *Wet* : 48–52 %) ainsi qu'une importante variabilité de diffusion lumineuse (*scattering*) sur les lots très humides.

- **Prétraitement** : Un enchaînement séquentiel rigoureux combinant une correction *Standard Normal Variate* (SNV) et un filtre dérivé de Savitzky-Golay de premier ordre (SG1, fenêtre de 25 points) a été appliqué pour s'affranchir des artefacts physiques et isoler les bandes d'absorption de l'eau (notamment autour de 5150 cm^{-1} et 6900 cm^{-1}).
- **Validation** : Pour éliminer tout risque de fuite de données (*data leakage*), la validation croisée *Leave-One-Group-Out* (LOGO) a été adoptée, garantissant que les répliques d'un même lot ne se retrouvent pas simultanément en entraînement et en test.

Résultats clés

Deux algorithmes de régression ont été confrontés sur un ensemble de test indépendant :

PLS (Partial Least Squares), optimisé à 3 composantes latentes par la méthode du coude et Random Forest (RF), paramétré à 500 arbres.

Il présente les résultats suivants :

	RMSE	MAE	R^2	Mean Bias
PLS	2,20	$1,75 \pm 1,32$	0,982	$1,07 \pm 1,92$
Random Forest	1,40	$1,23 \pm 0,67$	0,992	$0,99 \pm 0,99$

Limites et recommandations industrielles

Bien que le modèle Random Forest constitue une excellente preuve de concept avec des erreurs resserrées entre -2,0 et +2,0 %, il conserve une empreinte liée à la discontinuité initiale de la base de données (tendance à surestimer les extrêmes et sous-estimer la zone intermédiaire).

- **Prochaine étape** : Acquérir un échantillonnage continu couvrant les plages intermédiaires manquantes (notamment entre 20 et 30 %) pour éliminer le biais de structure.
- **Déploiement cible** : Implantation d'un capteur FT-NIR en ligne ou en bord de ligne couplé au modèle RF pour automatiser le pilotage des séchoirs et déclencher l'arrêt de la chauffe dès l'atteinte de la cible d'humidité (10-12 %).